Uso de modelos preditivos no âmbito de crimes de trânsito e de patrimônio viário no estado de São Paulo

Aline A. Sanches[1], **João G. Bruni Santeiro**[1], **Marianna Saltarelli A. Pontes**[1]

[1]Escola de Artes, Ciências e Humanidades – Universidade de São Paulo (USP)

Abstract. *The incidence of traffic offenses and road infrastructure crimes poses a critical challenge to public safety in the state of São Paulo, where traditional reactive policing methods have proven insufficient. This study investigates the capability of Machine Learning models in the spatial and temporal forecasting of road-related crimes across urban and highway networks. Integrating police incident reports from 2022 to 2025 with socioeconomic and demographic variables of the state, we evaluate and compare the effectiveness of three predictive algorithms. The scope encompasses offenses ranging from traffic-related homicides and negligent bodily injuries to cargo theft and vehicle theft/robbery. The goal of this research is to provide evidence that enables resource optimization and data-driven preventive policing in complex road environments.*

Resumo. *A ocorrência de crimes de trânsito e contra o patrimônio viário representa um desafio crítico para a segurança pública no estado de São Paulo, onde métodos tradicionais de policiamento reativo têm se mostrado insuficientes. Este estudo investiga a capacidade de modelos de aprendizado de máquina (Machine Learning) na previsão espacial e temporal de delitos viários ao longo da malha urbana e rodoviária. Integrando registros de boletins de ocorrência entre 2022 e 2025 com variáveis socioeconômicas e demográficas do estado, avaliamos e comparamos a eficácia de três algoritmos preditivos. O escopo abrange desde homicídios e lesões corporais culposas em acidentes até roubos de carga e furtos/roubos de veículos. O objetivo final desta pesquisa é fornecer evidências que viabilizem a otimização de recursos e o patrulhamento preventivo direcionado por inteligência de dados em ambientes viários complexos.*

1. Introdução

O estado de São Paulo, caracterizado por sua vasta e complexa malha viária, bem como por sua alta densidade demográfica, enfrenta desafios contínuos no âmbito da segurança pública. Dentre as infrações registradas, os crimes de trânsito e aqueles cometidos contra o patrimônio viário (como furtos de cargas, roubos em rodovias e vandalismo de infraestrutura) representam não apenas um risco direto à integridade dos cidadãos, mas também geram impactos econômicos substanciais. A mitigação dessas ocorrências exige estratégias de policiamento e alocação de recursos que vão além da reatividade, tornando a inteligência de dados uma ferramenta indispensável [Ramos et al. 2020].

A criminalidade é um fenômeno multifatorial, cujas dinâmicas espaço-temporais são influenciadas por variáveis contextuais [Kamalipour et al. 2014]. Embora a Secretaria de Segurança Pública do Estado de São Paulo (SSP-SP) forneça um amplo histórico de registros de boletins de ocorrência, a análise isolada dos dados puramente criminais limita

a capacidade de prever novos eventos. Estudos criminológicos demonstram que variáveis socioeconômicas e demográficas — frequentemente monitoradas por instituições como o Instituto Brasileiro de Geografia e Estatística (IBGE) — possuem forte correlação com a incidência criminal. O cruzamento dessas bases de dados permite uma modelagem mais robusta, incorporando o contexto ambiental e social em que os delitos ocorrem [Bogomolov et al. 2014].

Nesse cenário, o campo do Aprendizado de Máquina (Machine Learning) e da análise preditiva oferece metodologias capazes de identificar padrões complexos e não-lineares em grandes volumes de dados. A aplicação de algoritmos preditivos na segurança pública possibilita a antecipação de cenários de risco [Jenga et al. 2023], auxiliando os órgãos competentes na formulação de estratégias de prevenção e no patrulhamento direcionado, otimizando recursos humanos e logísticos.

Diante dessa lacuna, o presente artigo tem como objetivo avaliar e comparar o desempenho de diversos modelos preditivos na previsão espacial e temporal (local, data e horário) de crimes de trânsito e contra o patrimônio viário no estado de São Paulo. Para isso, o estudo integra dados criminais da SSP com indicadores socioeconômicos do IBGE. A fim de identificar a abordagem mais precisa e eficiente para este contexto específico, a pesquisa testa metodologias consagradas de classificação e regressão, compreendendo: Regressão Logística, Árvores de Decisão Impulsionadas por Gradiente (Gradient Boosting) e a arquitetura Multilayer Perceptron (MLP).

Através da análise comparativa das métricas de desempenho desses algoritmos, este trabalho busca não apenas apontar o modelo tecnicamente superior, mas também fornecer evidências empíricas que viabilizem a implementação de sistemas de segurança preventiva mais inteligentes nas rodovias e vias urbanas paulistas.

2. Trabalhos relacionados

Uma alta variedade de estudos relacionou associações e promoveu o uso de modelos preditivos na análise espacial de problemas urbanos nos últimos anos. No âmbito criminal e de trânsito, abordagens Data-Driven foram utilizadas internacionalmente para a predição de crimes violentos e colisões com vítimas fatais [Takyi et al. 2018]. No entanto, as características socioespaciais brasileiras possuem uma especificidade mais restrita e necessitam de uma análise precisa.

Nesse contexto de modelagem espacial de eventos viários no Brasil, o trabalho de [Adriano de Melo Costa 2021] propõe um modelo de predição da taxa de acidentes de trânsito com vítimas na cidade do Recife, Pernambuco. Apoiando-se no processo CRISP-DM e utilizando a ferramenta Orange, os autores integraram bases de dados abertas da Autarquia de Trânsito e Transporte Urbano (CTTU) correspondentes ao período de junho de 2015 a fevereiro de 2020. Entre as técnicas de aprendizado de máquina avaliadas — Regressão Linear, redes neurais artificiais (MLP), Support Vector Machines (SVM) e Random Forest —, o algoritmo Random Forest apresentou o desempenho mais robusto, alcançando uma taxa de erro absoluto médio de 13 acidentes por mês.

Também focado no cenário nacional, mas priorizando a consistência e a integração de dados para trechos de rodovias federais, o estudo de [Führ 2025] investigou a predição de acidentes na rodovia BR-101 em Santa Catarina. O autor identificou que os registros originais da Polícia Rodoviária Federal (PRF) apresentavam severas inconsistências

físicas (com 74,15% das ocorrências registradas para o mesmo trecho de 100 metros contendo divergências em atributos de via como traçado, tipo de pista e uso do solo). Para mitigar esse problema, o autor implementou uma metodologia de enriquecimento sequencial de dados, unificando os registros da PRF com os dados físicos da Agência Nacional de Transportes Terrestres (ANTT), dados climáticos da API Open-Meteo e estatísticas de tráfego (VMDA) do DNIT. Avaliando os modelos Random Forest, SVM e MLP, os resultados indicaram que a correção de inconsistências foi a etapa mais determinante para o ganho de performance (com elevações de até 7% na sensibilidade do SVM), e revelaram que o atributo espacial de quilometragem exerceu forte dominância na modelagem preditiva em trechos concentrados.

A transição da predição puramente focada em acidentes para o âmbito integrado da segurança pública e da criminalidade rodoviária é abordada por [da Silva Ramos 2024]. Em sua investigação aplicada na Academia Militar de Portugal, o autor explorou a utilidade de Sistemas de Informação Geográfica (SIG) e de Inteligência Artificial (IA) no combate à Criminalidade cometida em Ambiente Rodoviário (CcAR). Através de uma abordagem qualitativa sustentada por inquéritos por entrevista com especialistas e comandantes da Guarda Nacional Republicana (GNR), o trabalho avaliou a eficácia de mecanismos de policiamento proativo e preditivo (Intelligence-Led Policing). Foram destacados o sistema de radares SINCRO para moderação de velocidade, a tecnologia de comunicação DSRC para detecção eletrônica de crimes de falsificação de notação técnica e viciação de tacógrafos, e especialmente o projeto MOPREVIS (desenvolvido no distrito de Setúbal), que combina o mapeamento de hotspots em ambiente SIG com algoritmos de Machine Learning para otimizar a alocação de recursos preventivos no terreno.

Apesar da relevância e da atualidade dos trabalhos relacionados, a maioria dos estudos se restringe aos acidentes no espaço urbano ou a análises qualitativas de sistemas de segurança, sem avaliar comparativamente modelos preditivos quantitativos para a totalidade dos crimes de trânsito e de patrimônio viário em ambiente de rodovia. Portanto, faz-se necessário avaliar a eficiência de modelos preditivos para esses crimes no contexto específico deste estudo, no estado de São Paulo, cruzando o histórico de boletins de ocorrência da SSP-SP com as variáveis socioeconômicas e demográficas do IBGE.

3. Método

O estudo utiliza uma abordagem quantitativa, com uso de algoritmos de machine learning, para tratar do tema e buscar solucionar seu objetivo. Com isso, pretende-se detalhar e relacionar os fatores que influenciam a incidência de crimes de trânsito. A metodologia consiste em quatro etapas: coleta de dados, pré-processamento de dados, treinamento de modelos preditivos e análise. O estudo foca, inicialmente, em crimes de trânsito e de patrimônio viário que podem ser localizados por Registros de Ocorrência (RO) no estado de São Paulo, Brasil. Além de ser o estado mais populoso e denso do Brasil, São Paulo conta com uma documentação vasta e completa de seus dados criminais. Os crimes considerados para este estudo são: homicídio doloso e culposo por acidente de trânsito, lesão corporal culposa por acidente de trânsito, roubo de veículo, roubo de carga e furto de veículo.

Coleta de Dados

Os dados criminais utilizados para o estudo foram obtidos a partir de bases de

dados públicas, disponibilizadas pela Secretaria de Segurança de São Paulo (SSP). Os registros destes incidentes datam do ano de 2022 até 2026, somando 919.988 ocorrências no total. Cada base de dados possui informações sobre o horário, data, local (em coordenadas geográficas), tipo de crime e número de feridos e mortos. Para adicionar contexto e poder preditivo aos modelos testados, coletamos e adicionamos ao nosso conjunto de dados estatísticas relativas a fatores socio-econômicos, mais especificamente:

- Índice de Gini;
- Densidade demográfica;
- Salário médio mensal;

Sendo os dados obtidos através do Portal Cidades, do Instituto Brasileiro de Geografia e Estatística (IBGE, disponível em: https://cidades.ibge.gov.br/brasil/sp/sao-paulo/panorama, data de acesso: 24 de setembro de 2026). A escolha destes fatores se justifica pela correlação possibilidade de correlação entre eles e crimes violentos (o caso dos crimes que selecionamos), como pode ser verificado na literatura criminológica e de estatística espacial, incluindo estudos robustos como [Cerqueira and Lobão 2004] e [Bogomolov et al. 2014].

Pré-processamento dos Dados

Com a finalidade de preparar os dados para a análise, será utilizada a linguagem Python e bibliotecas especializadas para a ciência de dados como o pandas e numpy. Como recomendado por [McKinney 2022], começamos nosso pré-processamento eliminando entradas duplicadas ou que contenham colunas vazias, mal-formatadas ou corrompidas. Nesta etapa, também removemos todas as entradas que representavam incidentes ou crimes que fogem do escopo da análise, como latrocínio ou estupro, bem como entradas fora do período desejado (2021 a 2026). Ao fim deste processo, reduzimos o número de registro de 4.8 milhões para 920 mil.

Escolha de Modelos Preditivos

Com base na meta-análise de artigos correlatos, definimos uma lista de modelos comumente usados para objetivos semelhantes, incluindo Regressão Logística, Árvore de Decisão Impulsionada por Gradiente e Multi-Layer Perceptrons.

4. Cronograma

Tabela 1. Cronograma de Atividades

Atividades	Meses				
	AGO	SET	OUT	NOV	DEZ
Definir tema e objetivo	X				
Bibliografia e estruturação	X				
Coleta de dados	X	X			
Análise dos dados		X			
Limpeza dos dados		X			
Transformação dos dados		X	X		
Especificação de modelos			X		
Desenvolvimento e treinamento			X		
Avaliação e previsão			X	X	
Análise dos resultados				X	
Introdução e trabalhos correlatos				X	
Resumo, métodos e resultados				X	X
Conclusão e discussão					X

5. Resultados preliminares

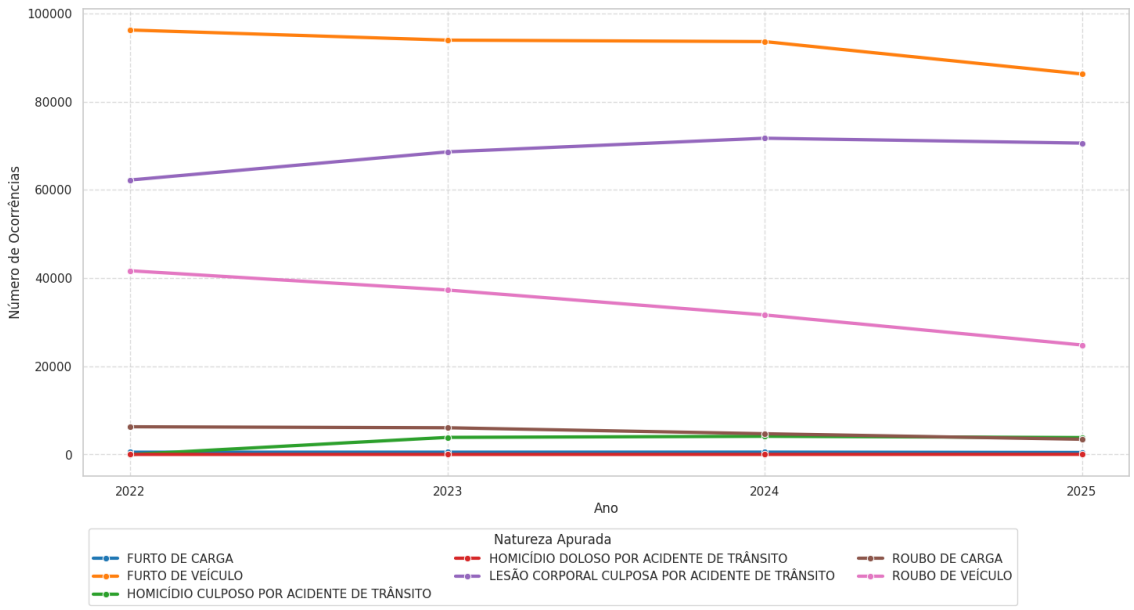


Figura 1. Evolução anual de ocorrências por natureza

A análise exploratória inicial revela a evolução temporal do número de ocorrências criminais absolutas entre 2022 e 2025, categorizadas por natureza do delito (Figura 1). Observa-se uma predominância expressiva dos crimes de furto e roubo de veículos em comparação aos crimes contra a vida no trânsito (homicídios culposo e doloso). Nota-se, ainda, uma tendência de estabilidade com leve declínio nos crimes patrimoniais ao longo

do período analisado, evidenciando a dinâmica volumétrica que os modelos preditivos precisarão assimilar.

Avançando além da quantificação absoluta, a análise passa a se concentrar na estruturação preditiva, voltando-se às circunstâncias espaciais e temporais dessas ocorrências. O foco inicial recai sobre a localização do crime. Em termos absolutos, o município de São Paulo destaca-se imediatamente, compreendendo mais de 50% das ocorrências totais no período. Em seguida, figuram as outras cidades mais populosas do estado: Campinas, Santo André e Guarulhos. A distribuição geográfica dessas ocorrências pode ser visualizada no gráfico de dispersão espacial (Figura 2), que mapeia a alta densidade de eventos na Região Metropolitana e ao longo dos principais eixos da malha viária estadual.

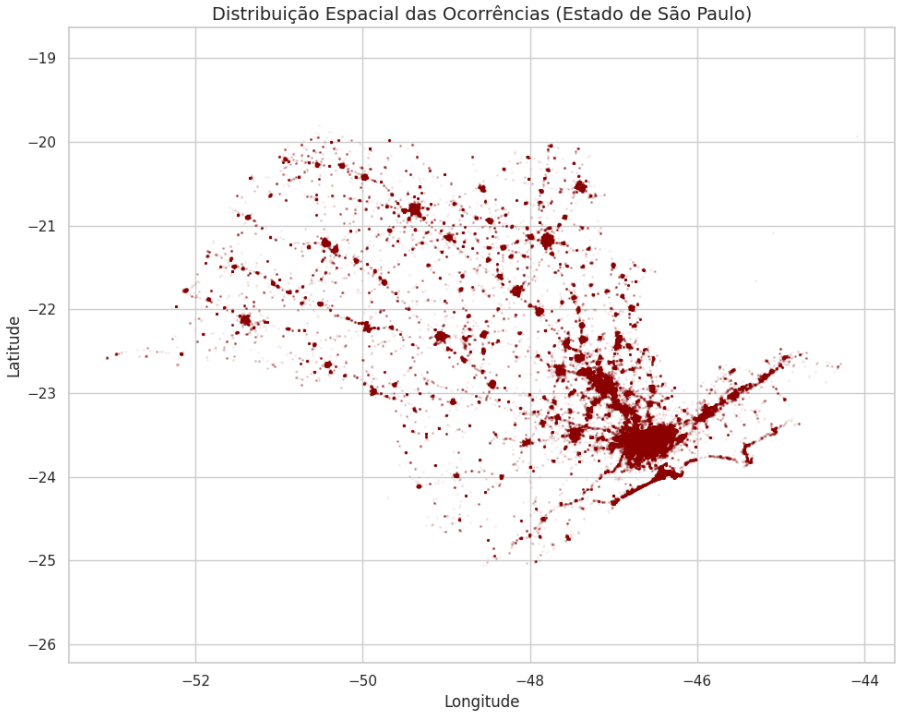


Figura 2. Distribuição Espacial das Ocorrências de crimes de trânsito e patrimônio viário (Estado de São Paulo)

Contudo, para uma avaliação comparativa mais acurada da criminalidade entre os municípios, o uso de ocorrências relativas por 1.000 habitantes revela-se uma métrica mais adequada, pois demonstra a incidência de crimes proporcionalmente à população local. Com isso, obtém-se a relação de cidades objetivamente mais críticas, o que expõe uma distribuição substancialmente diferente daquela baseada apenas em dados absolutos. Nesse contexto, o primeiro lugar é ocupado por Santo André, seguido por municípios do interior como Votuporanga e Jales, enquanto a capital paulista aparece apenas na 15ª posição, conforme ilustrado na Figura 3.

Além da dimensão espacial, a análise da temporalidade é um fator determinante para a predição. O mapeamento temporal — estruturado por meio de mapas de calor cruzando os dias da semana com as faixas horárias do dia — indica os momentos de maior vulnerabilidade na infraestrutura viária (Figura 4). Nota-se uma forte concentração



Figura 3. Municípios de São Paulo com a maior taxa de ocorrências por mil habitantes

de crimes nos dias úteis durante o fim do horário comercial. Essa granularidade espaço-temporal fornece as variáveis (features) fundamentais para que os algoritmos de Machine Learning selecionados alcancem alto desempenho em suas previsões.

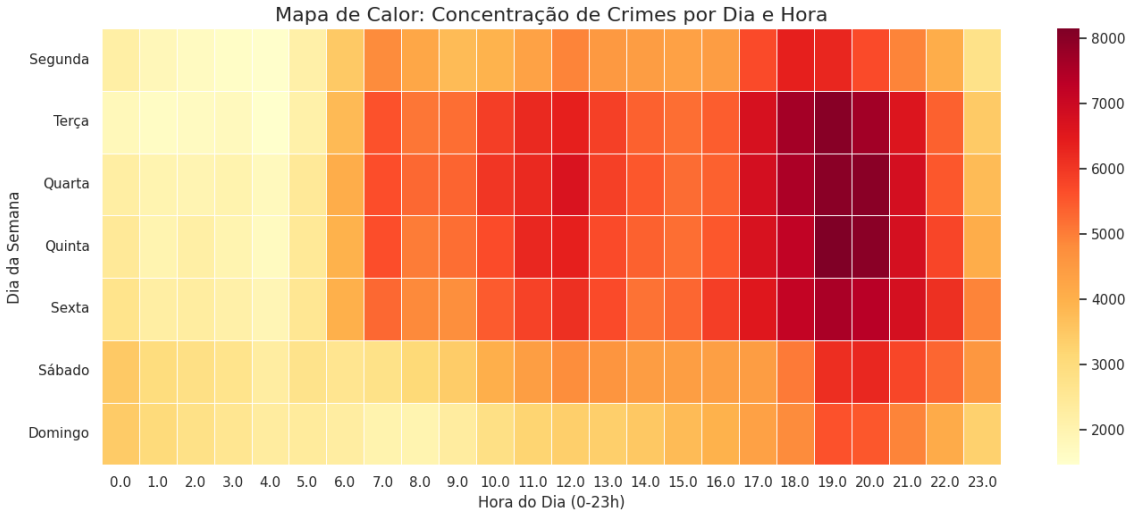


Figura 4. Mapa de calor com dias da semana e horários do dia

,

Predição de crimes

6. Discussão dos resultados

Olhando para os dados levantados entre 2022 e 2025, fica claro que entender a relação entre espaço e tempo é fundamental para mapear a criminalidade viária. A grande diferença de volume entre os furtos/roubos de veículos e os crimes de trânsito com vítimas mostra que os crimes patrimoniais seguem uma lógica muito própria, ligada a fatores socioeconômicos. Essa relação com indicadores sociais vai ao encontro do que [Cerqueira and Lobão 2004] apontam sobre as motivações para a criminalidade.

No aspecto espacial, os resultados mostram por que não podemos olhar apenas para os números absolutos. A cidade de São Paulo concentra mais da metade de todas as ocorrências e mesmo assim, quando calculamos a taxa em relação ao número de habitantes, a realidade muda bastante. Isso reforça a ideia de [Bogomolov et al. 2014] de que

usar só o volume de boletins de ocorrência é insuficiente, fazendo-se necessário o cruzamento os dados criminais da SSP-SP com as informações demográficas do IBGE.
Por fim, a análise temporal confirma que as ocorrências viárias possuem relação com a rotina da população, com a maior frequência de incidentes ocorrendo em dias úteis e coincidindo com o momento de maior fluxo de veículos nas vias urbanas e rodoviárias, mostrando como o ambiente e as dinâmicas de deslocamento afetam a ocorrência de delitos e acidentes em um contexto alinhado ao que argumentam [Kamalipour et al. 2014]. Por causa da relação entre horários, locais e indicadores sociais como fatores determinantes da criminalidade, justifica-se o uso de algoritmos preditivos a fim de cruzar essas variáveis para antecipar riscos e ajudar na segurança pública.

7. Conclusão

O objetivo deste trabalho foi investigar o uso de modelos preditivos para antecipar crimes de trânsito e contra o patrimônio viário no estado de São Paulo, integrando registros criminais da SSP com variáveis socioeconômicas do IBGE. Nesta fase inicial, a etapa de pré-processamento e análise exploratória foi fundamental para filtrar os cerca de 4,79 milhões de boletins de ocorrência originais, resultando em uma base limpa de aproximadamente 813 mil registros essenciais para mapear a complexidade do problema.
Os resultados revelaram que o risco criminal nas rodovias e vias urbanas não pode ser medido apenas pelo volume absoluto de ocorrências, o que torna o cálculo de taxas proporcionais à população uma etapa essencial para não mascarar a realidade dos municípios menores. Além disso, a forte ligação dos incidentes com os dias úteis e a rotina de deslocamento confirma que a criminalidade é influenciada diretamente pelo ambiente e pelas dinâmicas da sociedade.
Como a análise demonstrou que a segurança viária depende do cruzamento de diversas informações de tempo, espaço e indicadores sociais, o uso de algoritmos preditivos se justifica plenamente. Como próximos passos, a pesquisa utilizará essa base de dados limpa e estruturada para treinar e comparar os modelos de Regressão Logística, Árvores de Decisão (Gradient Boosting) e Multilayer Perceptron (MLP). A expectativa é que essas ferramentas analíticas aprendam com os padrões identificados e viabilizem um patrulhamento preventivo direcionado por inteligência de dados, otimizando a alocação de recursos na malha viária paulista.

Referências

Adriano de Melo Costa, Arthur Guilherme Oliveira de Freitas, R. P. P. (2021). Mineração de dados na construção de modelo de predição de acidentes com vítimas em recife. *Revista de Engenharia e Pesquisa Aplicada*, 6(3).

Bogomolov, A., Lepri, B., Staiano, J., Oliver, N., Pianesi, F., and Pentland, A. (2014). Once upon a crime: Towards crime prediction from demographics and mobile data.

Cerqueira, D. and Lobão, W. (2004). Determinantes da criminalidade - cerqueira e lobão - dados a02v47n2. *Dados*, 47:233 a 269.

da Silva Ramos, J. P. (2024). O uso dos sistemas de informação geográfica como meio de predição de crimes cometidos em ambiente rodoviário. Master's thesis, ACADEMIA MILITAR.

Führ, G. K. (2025). Predição de acidentes rodoviários em santa catarina: o papel do enriquecimento de dados no desempenho dos modelos. Master's thesis, UNIVERSIDADE FEDERAL DE SANTA CATARINA.

Jenga, K., Catal, C., and Kar, G. (2023). Machine learning in crime prediction. *Journal of Ambient Intelligence and Humanized Computing*, 14:1–27.

Kamalipour, H., Faizi, M., and Memarian, G. (2014). Safe place by design: Urban crime in relation to spatiality and sociality. *Current Urban Studies*, 2:152–162.

McKinney, W. (2022). *Python for Data Analysis*. O'Reilly.

Ramos, S., Pérez-López, J. , and Abreu, R. (2020). An analysis of the importance of the artificial intelligence on the information system of police forces. In *2020 15th Iberian Conference on Information Systems and Technologies (CISTI)*, pages 1–7.

Takyi, E. A., Oluwajana, S. D., and Park, P. Y. (2018). Development of macro-level crime and collision prediction models to support data-driven approach to crime and traffic safety (ddacts). *Transportation Research Record*, 2672(33):56 – 66.